

인공지능 학습 결과서

유튜버 이탈 예측 모델 개발 및 성능 분석

YouTube Creator Churn Prediction — Ensemble Learning Report

프로젝트명	TubeEottae (튜브어때) — AI 기반 크리에이터 이탈 예측 시스템
팀	SKN30-2nd-1Team
작성일	2026년 05월 22일
모델 버전	최종 리밸런싱 앙상블 (Threshold = 0.385)
적용 알고리즘	XGBoost + LightGBM + Logistic Regression (Soft Voting)

1. 개요 및 목표 설정

▶ 학습 목적

YouTube 채널의 업로드 패턴, 규모, 반응성, 민감 콘텐츠 지표를 기반으로 향후 이탈 가능성이 높은 유튜버를 조기에 탐지하여 광고주·MCN의 채널 선정 및 리스크 관리를 지원한다.

▶ 문제 정의 및 적용 모델

본 프로젝트는 지도학습 기반 이진 분류(Binary Classification) 문제로 설계하였다. 클래스 불균형(약 4:1)을 고려하여 앙상블 모델과 임계값 최적화를 적용하였다.

구분	모델	불균형 보정 방법	역할
①	XGBoost	scale_pos_weight = 5.704	트리 기반 앙상블, 과적합 방지
②	LightGBM	scale_pos_weight = 7.606	고속 경사 부스팅, 리프 중심 분기
③	Logistic Regression	class_weight = 'balanced'	선형 기저 모델, 해석 용이성
결합	Soft Voting Ensemble	—	소프트 보팅으로 확률 평균 앙상블

- 소프트 보팅: `VotingClassifier(..., voting="soft")`
- 임계값 튜닝: `find_best_threshold()`로 Validation 기반 threshold = 0.385 선택

2. 데이터셋 수집 및 전처리

▶ 데이터 출처 및 수집 과정

- 국내 유튜브 채널 순위 사이트(youtube-rank.com)에서 채널 ID 및 기본 정보 9,427개 수집
- 1차 전처리 후 8,084개로 정제 → 구독자 수 10만~100만 구간 한정
- 뉴스/정치/사회, 회사/오피셜, 기업/공공기관 채널 제외 → 개인 크리에이터 중심 3,331개 선정
- YouTube Data API로 채널 상세 정보 및 최신 영상 50개 수집 (영상 시계열 총 166,450건)
- yt-dlp로 채널당 최신 10개 영상의 댓글 100개 수집 → KcELECTRA 기반 긍·부정 감성 분석

▶ 데이터 규모 및 타깃 분포

구분	채널 수	비율	설명
정상 채널 (Class 0)	2,637개	79.17%	기준 시점 이후 활동 채널
이탈 채널 (Class 1)	694개	20.83%	기준 시점 이후 180일 이상 미업로드
전체	3,331개	100%	입력 형태: preprocessed.csv (3331 × 45)

※ 약 4:1 클래스 불균형 존재 → 이탈 채널 탐지에 편향 최소화 전략 적용

▶ 전처리 및 피처 엔지니어링

- 채널 규모, 업로드 패턴, 조화·반응성, 규칙성, 민감 콘텐츠 관련 변수 구성 → 총 41개 학습 피처 생성
- 이탈 라벨: 기준 시점 이후 180일 이상 업로드가 없는 채널을 이탈 채널(1)로 정의
- 클래스 불균형 대응: class_weight, scale_pos_weight, F2-score 기반 튜닝, Validation 기반 threshold search 적용

3. 모델 학습 및 튜닝

▶ 학습 환경

Python 환경에서 pandas, numpy, scikit-learn, xgboost, lightgbm, imbalanced-learn, shap 등을 사용하였다.

▶ 기준 모델 vs 리밸런싱 모델 비교

항목	기준 모델	최종 리밸런싱 모델
파일	best_ensemble_tuning_pipeline.ipynb	best_ensemble_tuning_pipeline_reb.ipynb
데이터 분할	Train 80% / Test 20%	Train 60% / Validation 20% / Test 20%
교차 검증	Stratified 3-Fold CV	Stratified 5-Fold CV
최적화 지표	ROC-AUC	F2-score (RandomizedSearchCV)
임계값 탐색	기본값 0.50	Validation Recall $\geq$ 80% 기반 → 0.385
양상블 구성	RandomForest + GradientBoosting + LightGBM	XGBoost + LightGBM + LogisticRegression

▶ 주요 하이퍼파라미터


모델	주요 파라미터	설명
XGBoost	n_estimators=200, max_depth=3 learning_rate=0.03 scale_pos_weight=5.704, reg_lambda=10	얕은 트리로 과적합 방지 클래스 불균형 보정 강화
LightGBM	n_estimators=200, max_depth=4 learning_rate=0.03, num_leaves=15 scale_pos_weight=7.606	리프 기반 분기로 고속 학습 불균형 보정 가장 강하게 설정
Logistic Regression	penalty='l1', C=0.1 class_weight='balanced'	L1 정규화로 변수 선택 효과 균형 잡힌 클래스 가중치

4. 결과 및 성능 평가

▶ 최종 테스트 세트 핵심 지표 요약

지표	기준 모델	최종 모델	변화	비즈니스 의미
Test Accuracy	0.8096	0.6522	↓	전체 정확도 하락 (허용 범위)
Precision (이탈)	0.5938	0.3604	↓	오경보율 증가 (비용 통제 가능)
Recall (이탈)	0.3200	0.8633	↑↑	이탈 탐지 핵심 지표 대폭 향상
F1-Score (이탈)	0.4205	0.5085	↑	정밀도·재현율 균형 개선
F2-Score (이탈)	0.3534	0.6749	↑↑	Recall 가중 종합 점수 향상
ROC-AUC	0.7962	0.7949	≈	전체 분류 능력 유지

기준 모델 vs 최종 모델 성능 비교





▲ 기준 모델 vs 최종 모델 주요 지표 비교

▶ 상세 분류 리포트 (Test Set)

클래스	Precision	Recall	F1-Score	Support
Class 0 (정상 채널)	0.94	0.60	0.73	528
Class 1 (이탈 채널)	0.36	0.86	0.51	139
Accuracy	—	—	0.65	667
Weighted Avg	0.82	0.65	0.68	667

▶ 혼동 행렬 및 후보 모델 ROC-AUC 비교




▲ (좌) 혼동 행렬: TN=315, FP=213, FN=19, TP=120 (우) 후보 모델 Validation ROC-AUC 비교

▶ 결과 분석 요약

- False Negative 대폭 감소: 95개 → 19개 (이탈 채널 미탐지 80% 감소)
- False Positive 증가: 32개 → 213개 (정상 채널 오경보율 증가, 비용 통제 필요)
- 조기 경보 목적에는 최종 모델이 적합하며, Precision 손실은 2차 검토 프로세스로 보완 가능

4-2. 설명 가능한 AI — SHAP 변수 중요도 분석



▲ SHAP 글로벌 변수 기여도 (이탈 발생/방어 영향력 순위)

순위	변수명 (Feature)	SHAP 기여도	인사이트
1위	구독자 수 (subscriber_count)	25.0%	채널 규모가 이탈 여부에 가장 큰 영향
2위	업로드 규칙성 (regularity_score)	18.0%	불규칙 업로드 → 이탈 위험 상승
3위	수집 영상 수 (collected_video_count)	14.0%	전체 활동 볼륨과 이탈 간 관계
4위	30일 최저 구독자 (future_count_l30)	12.0%	단기 구독자 감소 조기 경보 지표
5위	채널 총 조회수 (total_views)	8.0%	누적 반응성과 지속 활동 연계
6위	평균 조회수 (avg_view_count)	6.0%	영상 당 반응성, 채널 매력도 지표
7위	민감 콘텐츠 점수 (sensitive_score)	4.0%	성인·논란성 콘텐츠 이탈 유발 가능

5. 결론 및 활용 방안

▶ 비즈니스적 시사점

- 최종 모델은 광고주와 MCN이 이탈 가능성이 높은 채널을 사전에 탐지하는 조기 경보 시스템으로 활용 가능
- MCN: 크리에이터 이탈로 인한 광고 수익 손실·채널 운영 리스크를 선제적으로 관리
- 광고주: 협업 채널의 안정성을 사전 검증하여 ROI 리스크 최소화

▶ 실무적 채널 리스크 관리 가이드라인 (Business Strategy)

전략	내용
크리에이터 등급별 Dynamic Threshold	1등급 (구독자 상위 5%): Threshold=0.38 적용, 이탈 탐지 강화 2등급 이하: 더 완화된 임계값 적용, 광고 투자 비용 대비 최적화

SHAP 리스크 예산 필터링 전략	구독자 수 높고 업로드 규칙성 낮으면서 sensitive_score 높은 채널 → 조기 경고 플래그 30일 최저 구독자(future_count_l30) 급감 채널 → 집중 모니터링
Streamlit 대시보드 연동	실시간 이탈 의심 채널 탐지 결과를 대시보드에 노출 채널별 리스크 등급, 주요 SHAP 변수 기여도 시각화 제공

▶ 향후 개선 과제

- Precision 개선: 크리에이터 등급·마케팅 예산 규모에 따라 threshold를 차등 적용하는 전략 도입
 - 파이프라인 통합: Logistic Regression 안정적 활용을 위해 StandardScaler 포함 통합 파이프라인 구성
 - 피처 확장: 댓글 감성·커뮤니티 반응 지표 추가 반영으로 모델 설명력과 정밀도 개선
 - 실시간 예측: 주기적 API 재수집 + 온라인 학습 도입으로 모델 최신성 유지
-