

youtube_model_db EDA 통합 레포트

유튜브 채널 이탈(Churn) 예측 모델 구축을 위한 탐색적 데이터 분석

📅 기준일: 2026-05-18

⚠️ 이탈: 마지막 업로드 180일 이상 경과

📦 DB: youtube_model_db

🎯 최종 데이터셋: 3,331채널 × 41피쳐

📑 목차

1. 1단계: 채널 기본 현황
2. 2단계: 카테고리(장르) 분석
3. 3단계: 채널 분석 지표 탐색
4. 4단계: 채널 스코어 분석
5. 5단계: 예측 결과 검토
6. 전처리 요약

1

1단계: 채널 기본 현황

channel_info_table

전체 채널

6,546개

활성 채널

4,729개

이탈 채널

1,817개 (27.8%)


구독자 평균

627K

이탈 임박 채널

308개

채널 기본 현황 (channel_info_table)



① Donut

이탈 vs 활성 채널 비율

전체의 27.8%가 이탈. 4채널 중 1채널 이상 이탈 — 예측 모델의 실용적 필요성 확인.

② Histogram

구독자 수 분포 (log scale)

극단적 우편향. 활성 채널 피크 100K~1M, 이탈 채널 피크 1K~100K. 구독자 수가 이탈의 강한 선행 지표.

③ Box Plot

그룹별 구독자 수 비교

활성 중앙값 ≈ 200K, 이탈 ≈ 50K (4배 차이). 이탈 채널 IQR이 더 좁아 저구독자 집중.

④ Bar+Line

구독자 구간별 이탈율

구독자 증가 → 이탈율 단조 감소: ~1K(71.8%) → 10M+(4.5%). 소규모 채널 고위험군.

⑤ Bar+Line

채널 개설 연도별 분포 & 이탈율

2014~2017년 개설 채널 이탈율 고점(33~35%). 최근 채널의 낮은 이탈율은 우측 절단(right censoring) 효과.

⑥ Stacked Bar

마지막 업로드 경과일별 구성

180일 기준으로 이탈/활성 완벽 분리 (정의에 의한 결과). 91~180일 공백 308개 = 이탈 임박 위험군.

💡 **요약:** 구독자 수가 이탈과 가장 강하게 연관. 업로드 공백이 이탈의 직접 정의 지표. 이탈 임박 위험군(308개) 선제 대응 가능.

2 단계: 카테고리(장르) 분석

channel_category_table × category_table

카테고리 수

37개

고유 장르 조합

17개

미분류 채널

1,358개 (20.7%)


최고 이탈 장르

어린이+키즈 41.0%

최저 이탈 장르

경제+부동산+주식 5.0%

카테고리(장르) 분석



① Bar (색상=이탈율)

장르별 채널 수 & 이탈율

② 이탈율 Bar

장르별 이탈율 순위

37개 카테고리는 독립 태그가 아닌 17개 장르 그룹 단위. 어린이+키즈·TV+방송 볼륨 크고 이탈율도 높음.

이탈율 범위 5%~41% (36%p 차이) → 장르가 유의미한 예측 피처. 경제·스포츠가 저이탈, 키즈·반려동물이 고이탈.

③ Scatter

볼륨 vs 이탈율

볼륨과 이탈율 간 단순 선형 상관 없음. 장르 고유 특성이 이탈율을 결정하는 핵심 요인.

💡 요약: 37개 태그 → 17개 장르 그룹으로 축소 후 원-핫 인코딩 필요. 미분류 20.7% 처리 전략 확정 필요.

3

3단계: 채널 분석 지표 탐색

channel_analytics_table

분석 대상

3,336채널

avg_interval 활성화

6.3일

avg_interval 이탈

16.0일


avg_view 역설

이탈 > 활성화

upload_freq 이상값

활성 34%

채널 분석 지표 탐색 (channel_analytics_table)



① Bar+Line

업로드 간격별 채널 수 & 이탈율

간격 길수록 이탈율 단조 증가: 매일(5.9%) → 월 1회 미만(55.8%). avg_upload_interval_days는 마지막 공백 제외로 누수 없음.

②③ Box

업로드 간격 & 최대 공백 비교

이탈 채널 평균 간격 중앙값이 활성의 2배 이상. max_gap_days 이탈 중앙값은 활성의 4배(266일 vs 67.7일).

④⑤ Box

조회수 & 참여율 — 역설

이탈 채널 avg_view(24.3만) > 활성(17.8만). 이유: 이탈 채널 영상 평균 나이 1,443일(4년) vs 활성 201일 — video age bias.

⑥⑦ Shorts

Shorts 비율 & 조회수

활성 Shorts 36.3% > 이탈 25.3%. Shorts 출시 (2021) 이전 이탈 채널의 구조적 0 → shorts_ratio 제거 결정.

⑧ 이상값

upload_freq_change_rate

활성 34%(901개) 이상값($>10^8$). epsilon 설계 결함
(prev+1e-9)으로 값 폭발. 신뢰도 불량 → 제거.

💡 **요약:** 업로드 패턴(avg_interval, max_gap, hiatus_count)이 이탈과 가장 강하게 연관.
upload_freq_change_rate·avg_engagement_rate·shorts 계열 제거.

4

4단계: 채널 스코어 분석

channel_score_table

분석 대상

3,336채널

regularity 활성

0.6532

regularity 이탈

0.5104


불규칙 이탈율

52.3%

매우 규칙적 이탈율

6.0%

채널 스코어 분석 (channel_score_table)



① ② 팬 유형

팬 유형별 채널 수 & 이탈율

슈퍼팬(36.5%) 역설 — video age bias로 이탈 채널이 슈퍼팬 분류. fan_type_code 제거.

③ ④ regularity

업로드 규칙성 점수

가장 신뢰할 수 있는 핵심 피쳐. 불규칙(52.3%) → 매우 규칙적(6.0%) 단조 감소, 누수 없음.

⑤ active_viewer

활성 시청자 점수

이탈 채널이 높음 → video age bias. active_viewer_score, view_per_sub 모두 제거.

⑥ sensitive

민감도 점수

최근 영상 제목 분석 기반 → Shorts bias와 다른 케이스. 유효 피쳐로 유지.

⑦ 민감 카테고리

카테고리별 보유 비율

cat_aggro(공격성)이 압도적 다수. 이탈 채널의 민감 콘텐츠 비율이 낮음 — 자극 콘텐츠 채널이 지속 업로드 경향.

💡 **요약:** regularity_score가 이 테이블 최고 피쳐. active_viewer_score·view_per_sub·fan_type_code 제거. 민감 콘텐츠 피쳐 유지.

5

5단계: 영상 데이터 탐색

video_table

전체 영상

166,144개

Shorts 비율

34.0%

활성 영상 나이

201일 (0.6년)


이탈 영상 나이

1,443일 (4년)

영상 나이 차이

7.2배

영상 데이터 탐색 (video_table)



① 연도별

영상 수 & Shorts 비율

2025~2026년 집중 (활성 채널 최근 50개). Shorts 비율 2021 이전 5~15% → 2023 이후 35~40%로 급증.

② 연도별 조회수

오래된 영상일수록 평균 조회수 높음

2017년 91만 → 2026년 13만 (7배). video age bias의 직접 증거. 이탈 채널 avg_view가 높은 근본 원인.

③ 영상 나이

활성 vs 이탈 평균 영상 나이

활성 201일 vs 이탈 1,443일 (7.2배). 이 단 하나의 수치가 EDA 전반의 역설(avg_view, shorts_ratio, active_viewer_score)을 모두 설명.

⑤ 조회수 분포

Shorts vs 일반 영상

Shorts가 고조회수 구간에 더 집중. 알고리즘 노출 효과.

💡 요약: video_table에서 별도 피쳐 추출 없이 진행. analytics/score_table이 충분히 커버. video age bias 수치 확정(7.2배).

전처리 요약

3,331행 × 41피처

활성 2,637개 (79.2%) | 이탈 694개 (20.8%) | NULL 0개

처리 단계

- **STEP 01** analytics ∩ score 보유 채널 선택 (6,546 → 3,336)
구독자 10만↑ & 영상 50개↑
- **STEP 02** `channel_age_days` 파생 (기준일 - created_date)
- **STEP 03** `channel_age_days` < 365일 제거 (우측절단 보정, -5개)
- **STEP 04** 타깃(`is_churned`) 분리 & 식별자 제거
- **STEP 05** 누수 피처 제거 (`days_since_latest_video` 등)
- **STEP 06** `channel_analytics` JOIN — 불량 피처 5개 제거 후 10열 추가
- **STEP 07** `channel_score` JOIN — 중복·bias·NULL 12개 제거 후 11열 추가
- **STEP 08** 결측값 처리 (중앙값·0 대체)
- **STEP 09** 장르 원-핫 인코딩 `get_dummies(drop_first=True)` → 16더미
- **STEP 10** `channel_identifier` 분리 → 최종 X (3,331 × 41) ✓

제거된 피처 (주요)

사유	제거 컬럼
누수	<code>days_since_latest_video</code> , <code>latest_video_date</code> , <code>days_since_last_upload</code>
Video Age Bias	<code>avg_engagement_rate</code> , <code>active_viewer_score</code> , <code>view_per_sub</code> , <code>fan_type_code</code>
Shorts 시점 편향	<code>shorts_ratio</code> , <code>avg_shorts_view</code>
데이터 품질	<code>upload_freq_change_rate</code> (epsilon 결함, 활성 34% 이상값)
중복 (상관 1.0)	<code>mean_interval_days</code> , <code>std_interval_days</code> , <code>max_gap_days</code> (score 테이블)

최종 피처 41개

channel_info (4개)

- subscriber_count
- total_views
- video_count
- channel_age_days ★파생

channel_analytics (10개)

- collected_video_count
- avg_upload_interval_days
- std_upload_interval_days
- max_gap_days
- hiatus_count_30d
- avg_view_count
- std_view_count
- avg_like_count
- avg_comment_count
- avg_normal_view

channel_score (11개)

- regularity_score ★
- cv
- outlier_ratio
- gap_ratio
- sensitive_score
- n_sensitive_videos
- sensitive_video_ratio
- cat_politics
- cat_hate
- cat_aggro
- cat_adult_illegal

장르 더미 (16개, 기준: 미분류)

- genre_BJ+연예인+인물
- genre_IT+기술+컴퓨터
- genre_TV+방송
- genre_가수+댄스+음악
- genre_강의+교육
- genre_게임
- genre_경제+부동산+주식
- genre_국내+여행+해외
- genre_라이프+취미
- genre_레시피+요리+음식
- genre_만화+애니+영화
- genre_미용+패션
- genre_반려동물+애완
- genre_스포츠+운동
- genre_어린이+키즈
- genre_자동차

✅ 핵심 피처: regularity_score — 불규칙(52.3%) → 매우 규칙적(6.0%) 단조 감소, 누수 없음

youtube_model_db EDA 통합 레포트 · 기준일 2026-05-18 · 작성 2026-05-21